

به نام خدا

درس دید کامپیوتری

گزارش تمرین شماره دوم

علیرضا بانشی

95101185

## تمارين کامپیوتری

### قسمت اول

#### ◆ blockSize

Size cv::HOGDescriptor::blockSize

Block size in pixels. Align to cell size. Default value is Size(16,16).

#### ◆ blockStride

Size cv::HOGDescriptor::blockStride

Block stride. It must be a multiple of cell size. Default value is Size(8,8).

#### ◆ cellSize

Size cv::HOGDescriptor::cellSize

Cell size. Default value is Size(8,8).

#### ◆ gammaCorrection

bool cv::HOGDescriptor::gammaCorrection

Flag to specify whether the gamma correction preprocessing is required or not.

#### ◆ histogramNormType

int cv::HOGDescriptor::histogramNormType

histogramNormType

#### ◆ L2HysThreshold

double cv::HOGDescriptor::L2HysThreshold

L2-Hys normalization method shrinkage.

#### ◆ nbins

int cv::HOGDescriptor::nbins

Number of bins used in the calculation of histogram of gradients. Default value is 9.

#### ◆ nlevels

int cv::HOGDescriptor::nlevels

Maximum number of detection window increases. Default value is 64.

##### Examples:

[samples/tapi/hog.cpp](#).

#### ◆ oclSvmDetector

UMat cv::HOGDescriptor::oclSvmDetector

coefficients for the linear SVM classifier used when OpenCL is enabled

#### ◆ signedGradient

bool cv::HOGDescriptor::signedGradient

Indicates signed gradient will be used or not.

#### ◆ svmDetector

std::vector<float> cv::HOGDescriptor::svmDetector

coefficients for the linear SVM classifier.

#### ◆ winSigma

double cv::HOGDescriptor::winSigma

Gaussian smoothing window parameter.

#### ◆ winSize

Size cv::HOGDescriptor::winSize

Detection window size. Align to block size and block stride. Default value is Size(64,128).

این مقادیر در مقاله به شرح زیر است:

Winsize = 128x64

Cellsize = 4x4

Blocksize = 16x16

Blockstride = 4x4

Nbins = 9

## قسمت دوم

برای این که HOG یک تصویر را محاسبه کنیم ابتدا به کمک HOG descriptor پارامتر ها را ست می کنیم و سپس به کمک دستور `compute` آن را محاسبه می کنیم. کد این بخش در قسمت `section2` آمده است و نتایج در فایل `hog feature` ذخیره و پیوست شده است.

## قسمت سوم

در این قسمت با استفاده از توضیحات داده شده در صورت تمرین `patch` های مثبت و منفی را لود می کنیم. کد این قسمت در `section3` آمده است.

## قسمت چهارم

در این قسمت می خواهیم داده ها را لیبل بزنیم. برای این کار ابتدا تمامی `patch` ها را چه مثبت چه منفی در `X1` می ریزیم و سپس به ازای هر المان که در `X1` داریم ویژگی های HOG آن را استخراج می کنیم و در `X` می ریزیم. حالا `X` مجموعه تمامی داده های ماست. حالا لازم داریم بردار `y` را تشکیل دهیم که طول آن به اندازه `X` و هر المان آن با 0 و 1 بودن به ترتیب نگاتیو یا پوزیتیو بودن را تعیین می کند. برای این کار دو `np.array` با طول های متناسب با پیچ های مثبت و منفی تشکیل می دهیم و آن ها را با 1 و 0 پر می کنیم و در نهایت این دو بردار را کانکت می کنیم:

```
5 Y = np.array([1
6               for im in positive_patches])
7 Y1 = np.array([0
8               for im in negative_patches])
9
10 y = np.concatenate((Y,Y1),axis = 0)
```

حالا داده های ما آماده است و می توانیم یادگیری را آغاز کنیم. کد این قسمت در `section4` آمده است.

## قسمت پنجم

ابتدا باید داده های `train` و `test` را جدا کنیم. برای این کار از کد زیر استفاده می کنیم:

```
1 # split X and y into training and testing sets
2 from sklearn.model_selection import train_test_split
3 X_train,X_test,y_train,y_test=train_test_split(X,y,test_size=0.2,random_state=0)
```

با این کار 80 درصد داده ها را به train و 20 درصد را به تست اختصاص می‌دهیم.  
برای یادگیری از دو الگوریتم استفاده کرده‌ایم:

## 1. اول svm خطی و با استفاده از متد GridSearchCV

به کد زیر دقت کنید:

```
svclassifier = GridSearchCV(LinearSVC(), {'C': [1.0, 2.0, 4.0, 8.0]})
svclassifier.fit(X_train, y_train)
y_pred_svm_linear_test = svclassifier.predict(X_test)
y_pred_svm_linear_train = svclassifier.predict(X_train)
```

ابتدا در خط اول مدل را تشکیل می‌دهیم. سپس مدل را با داده های train فیت می‌کنیم.  
حالا داده های train و test را به کمک مدل predict می‌کنیم تا دقت روی هر دو را بدست بیاوریم.  
حالا به کمک کد زیر دقت را محاسبه می‌کنیم.

```
print("linear : Trainig data Accuracy:",metrics.accuracy_score(y_train, y_pred_svm_linear_train))
print("linear : Testing data Accuracy:",metrics.accuracy_score(y_test, y_pred_svm_linear_test))
```

نتیجه به قرار زیر می‌باشد:

```
linear : Trainig data Accuracy: 0.9973399641473428
linear : Testing data Accuracy: 0.9932924713773563
```

پارامتر های بهینه ای که به جواب بالا ختم شده است به قرار زیر است:

```
1 print(svclassifier.best_params_)
2
{'C': 2.0}
```

## 2. دو svm غیر خطی با کرنل rbf

در این قسمت برای تشکیل مدل کافیسیت از کد زیر استفاده کنیم:

```
svclassifier1 = SVC(kernel='rbf')
```

بقیه مراحل را مانند قسمت قبل انجام می‌دهیم نتیجه به قرار زیر می‌باشد:

```
rbf :Training data Accuracy: 0.9992771641704736
```

```
rbf : Testing data Accuracy: 0.9973401179599861
```

مشاهده می‌شود که با این متد دقت کمی بهتر است.  
زیرا دیتاها گستردگی زیادی دارند و svm غیر خطی به دلیل این‌که در فضای با بعد بالاتر داده‌ها را جدا می‌کند عملکرد بهتری دارد.  
کدهای این قسمت در section 5 آمده است.

### قسمت ششم

ابتدا 5 تصویر تست داده شده را می‌خوانیم و آن‌ها را با ضریب 5 rescale می‌کنیم سپس قسمت‌هایی از آن را کراپ می‌کنیم تا محاسبات در ادامه سریعتر شود و نتایج بهتری بگیریم.

```
test_image1 = cv2.imread('test_image1.jpg',0)
test_image1 = transform.rescale(test_image1, 0.5)
test_image1 = test_image1[20:300, 80:230]
```

کد این قسمت در ابتدای section 6 و در بخش Reading Test Images آمده است.  
خروجی تصاویر را مشاهده می‌کنیم:



حالا باید برای هر تصویر pyramid ها را حساب کنیم. برای این کار از دو روش زیر استفاده کردم .  
یک روش آماده با کمک تابع آماده موجود در کتابخانه skimage داده شده در تمرین:

```
pyramid = np.asarray(tuple(pyramid_gaussian(image)))
```

دو روش مشابه به کمک opencv

```
layer = image
gaussian_pyramid = [layer]
for i in range(7):
    layer = cv2.pyrDown(layer)
    gaussian_pyramid.append(layer)
```

حالا سعی کردم برای تصاویر بدست آمده از هر تصویر ویژگی های HOG را استخراج کنم که هر بار با ارور عجیب زیر مواجه شدم:

```
1 frames
/usr/local/lib/python3.6/dist-packages/skimage/feature/_hog.py in hog(image,
273     n_blocks_col = (n_cells_col - b_col) + 1
274     normalized_blocks = np.zeros((n_blocks_row, n_blocks_col,
--> 275                                     b_row, b_col, orientations))
276
277     for r in range(n_blocks_row):
ValueError: negative dimensions are not allowed
SEARCH STACK OVERFLOW
```

سپس با مشاوره از دوستان راه دیگری را انتخاب کردم.



روی تصاویر پرمایش می‌کنیم و پنجره‌های  $47 \times 62$  را انتخاب می‌کنیم. البته همه پنجره‌ها را ن و برای سادگی 16 بار 16 حرکت می‌کنیم. تابعی که این کار را انجام می‌دهد به شرح زیر است که بسیار ساده است:

```
1 def pyramid_fun(img):
2     for i in range(0, img.shape[0] - 62, 16):
3         for j in range(0, img.shape[1] - 47, 16):
4             # extracting window
5             patch = img[i:i + 62, j:j + 47]
6             yield (i, j), patch
7
```

صرفاً یک سری تصویر تشکیل می‌دهد و در دیکشنری می‌ریزد. حالا مصابق زیر دیکشنری تصاویر مرتبط با هر تصویر تست را بدست می‌آوریم. سپس ویژگی‌های hog هر ست را تشکیل می‌دهیم و نتایج را در یک np.array ذخیره می‌کنیم. مطابق زیر:

```
i1, p1 = zip(*pyramid_fun(test_image1))
i2, p2 = zip(*pyramid_fun(test_image2))
i3, p3 = zip(*pyramid_fun(test_image3))
i4, p4 = zip(*pyramid_fun(test_image4))
i5, p5 = zip(*pyramid_fun(test_image5))

test1_hog = np.array([feature.hog(patch) for patch in p1])
test2_hog = np.array([feature.hog(patch) for patch in p2])
test3_hog = np.array([feature.hog(patch) for patch in p3])
test4_hog = np.array([feature.hog(patch) for patch in p4])
test5_hog = np.array([feature.hog(patch) for patch in p5])
```


حال وقت آن رسیده است که این داده‌های جدید را به کمک مدل بدست آمده در قسمت قبل پیش‌بینی کنیم. ابتدا مدل را پردیکت می‌کنیم و سپس روی اندیس‌ها می‌گردیم و جاهایی که چهره تشخیص داده شده یعنی out1 برابر یک است یک مستطیل می‌کشیم. گوشه چپ بالا به کمک پنجره‌های پیش‌بینی شده توسط مدل بدست می‌آید و ابعاد مستطیل تقریباً مطابق با ابعاد صورت در تصویر تست است. کد این قسمت به قرار زیر است:

```

1 out1 = svcclassifier.predict(test1_hog)
2
3
4
5 fig, ax = plt.subplots()
6 ax.imshow(test_image1, cmap='gray')
7 ax.axis('off')
8
9 Ni, Nj = positive_patches[0].shape
10 indices = np.array(i1)
11 t=[]
12
13 for i, j in indices[out1 == 1]:
14
15     ax.add_patch(plt.Rectangle((j, i), 100, 140, edgecolor='red',
16                               alpha=0.3, lw=2, facecolor='none'))
17     print(j,i)
18     t.append((j,i,j+100,i+140))
19 tt = np.array(t)
20

```

همینطور محل همه مستطیل ها را در `tt` ذخیره می‌کنیم بعدا از آن استفاده می‌کنیم:  
خروجی برای تصویر به قرار زیر است:



مشاهده می‌شود که نتیجه قابل قبول است.  
حالا باید از `Non.Maximum.Suppression` استفاده کنیم که بهترین مستطیل را انتخاب کنیم.  
با جست و جو اینترنت تابع های آماده ای پیدا کردم که این کار را انجام می‌دهد.

لینک: [https://github.com/bruceyang2012/nms\\_python](https://github.com/bruceyang2012/nms_python)

کد های این قسمت در بخش Non.Maximum.Suppression آورده شده است.

حالا به این تابع همه مستطیل ها را ورودی می دهیم (در قسمت قبل در tt ذخیره کردیم و آن بهترین مستطیل را خروجی می دهد).  
کد این قسمت مطابق زیر است:

```
1 import numpy as np
2 import cv2
3 from google.colab.patches import cv2_imshow
4
5 import time
6 pick = non_max_suppression_fast(tt, probs=None, overlapThresh=0.3)
7
8 fig, ax = plt.subplots()
9 ax.imshow(test_image1, cmap='gray')
10 ax.axis('off')
11
12 Ni, Nj = positive_patches[0].shape
13 indices = np.array(indices4)
14 ax.add_patch(plt.Rectangle((pick[1][0], pick[1][1]), 100, 140, edgecolor='blue',
15                             alpha=0.3, lw=2, facecolor='none'))
16
```

نتیجه برای اولین تصویر به قرار زیر است:



حالا همین کار را برای بقیه تصاویر انجام می دهیم و نتایج را مشاهده می کنیم:

تصویر 2



تصویر 3



تصویر 4



تصویر 5



همه کد های مربوط به این قسمت ها به تفکیک تصویر تست زیر قسمت section 6 آمده است.